

Χατζηθεοδώρου Ιάσων 03117089

Αναγνώριση Προτύπων

1η Αναλυτική Εργασία

el17089@mail.ntua.gr

Άσκηση 1.1

Η κατανομή των δειγμάτων είναι η

$$p(x|\theta) = \theta^2 x e^{-\theta x} u(x)$$

Άρα περνώντας το λογάριθμο

$$\ln p(x|\theta) = 2\ln\theta - \theta x + \ln x \quad \text{για } x \geq 0$$

Παραγωγίζοντας ως προς θ

$$\frac{\partial \ln p(x|\theta)}{\partial \theta} = \frac{2}{\theta} - x$$

Άρα προκύπτει η παρακάτω εξίσωση για τη μεγιστοποίηση της πιθανοφάνειας

$$\sum_{i=1}^n \frac{2}{\theta} - x_i = 0$$

Η οποία λύνεται ως προς θ ως εξής

$$\theta = \frac{2n}{\sum x_i}$$

Άσκηση 1.2

Η εξίσωση για τη μέθοδο minimax είναι η εξής

$$\lambda_{11} + (\lambda_{21} - \lambda_{11}) \int_{R_2} p(x|\omega_1) dx = \lambda_{22} + (\lambda_{12} - \lambda_{22}) \int_{R_1} p(x|\omega_2) dx$$

Αντικαθιστώντας τις τιμές $\lambda_{11} = \lambda_{22} = 0$ και $\lambda_{12} = \lambda_{21} = 1$ έχουμε

$$\int_{R_2} p(x|\omega_1) dx = \int_{R_1} p(x|\omega_2) dx$$

Η παραπάνω λύση δεν είναι μοναδική ως προς τις δύο κατανομές. Σαν αντιπαράδειγμα μπορούμε να σκεφτούμε οποιεσδήποτε δύο κατανομές που περιορίζονται η κάθε μία στην περιοχή της. Άρα και τα δύο ολοκληρώματα προκύπτουν μηδέν και ισχύει η σχέση όμως οι κατανομές μπορούν να είναι οποιεσδήποτε.

Άσκηση 1.3

Στις δύο διαστάσεις η πιθανότητα σφάλματος είναι

$$P[2d \text{ error}] = \int_{D_{11}} \int_{D_{12}} p(x_1, x_2 | \omega_2) p(\omega_2) dx_2 dx_1 + \int_{D_{21}} \int_{D_{22}} p(x_1, x_2 | \omega_1) p(\omega_1) dx_2 dx_1$$

όπου προφανώς τα D_{ij} ορίζουν τις περιοχές απόφασης κάθε κατηγορίας. Για να υπολογίσουμε την προβολή ολοκληρώνουμε ως προς x_2 , οπότε η πιθανότητα σφάλματος στη μία διάσταση είναι

$$P[1d \text{ error}] = \int_{D_1} \int_{-\infty}^{\infty} p(x_1, x_2 | \omega_2) dx_2 * p(\omega_2) dx_1 + \int_{D_2} \int_{-\infty}^{\infty} p(x_1, x_2 | \omega_1) dx_2 * p(\omega_1) dx_1$$

όπου αντίστοιχα τα D_i ορίζουν τις περιοχές απόφασης. Τα D_i όμως δεν μπορούν να μην περιέχουν τα D_{i1} , γιατί στις δύο διαστάσεις οι περιοχές έχουν επιλεγεί έτσι ώστε να ελαχιστοποιείται η πιθανότητα σφάλματος χρησιμοποιώντας περισσότερη πληροφορία από ότι στη μία διάσταση. Άρα προκύπτουν οι εξής σχέσεις

$$\int_{-\infty}^{\infty} p(x_1, x_2 | \omega_2) dx_2 * p(\omega_2) = \int_{-\infty}^{\infty} p(x_1, x_2 | \omega_2) p(\omega_2) dx_2 \geq \int_{D_{12}} p(x_1, x_2 | \omega_2) p(\omega_2) dx_2$$

επειδή η πιθανότητα είναι πάντα μη αρνητική και

$$\int_{D_1} \int_{-\infty}^{\infty} p(x_1, x_2 | \omega_2) dx_2 * p(\omega_2) dx_1 \geq \int_{D_{11}} \int_{D_{12}} p(x_1, x_2 | \omega_2) p(\omega_2) dx_2 dx_1$$


επειδή $D_{11} \subseteq D_1$. Ομοίως για το ολοκλήρωμα στη περιοχή του ω_2 . Άρα τελικά ισχύει

$$P[1d \text{ error}] \geq P[2d \text{ error}]$$

Το παραπάνω αποτέλεσμα ισχύει και στην κανονική κατανομή ως ειδική περίπτωση.

Άσκηση 1.4

Σχεδιάζοντας τα σημεία προκύπτει η εξής εικόνα, από την οποία είναι προφανές πως οι κλάσεις είναι γραμμικά διαχωρίσιμες



Για διάνυσμα βαρών $w = [0, 0]$ το perceptron από ένα σημείο και μετά κάνει πάντα λάθος στα δείγματα $(-2, 1)$ και $(2, -0.5)$. Αυτό συμβαίνει γιατί χωρίς το w_0 , η ευθεία που προσπαθεί να βρει περνάει από την αρχή των αξόνων και όπως φαίνεται στο σχήμα μια τέτοια ευθεία δεν θα μπορούσε να διαχωρίσει τις δύο κλάσεις.


Για $w = [0, 0, 0]$ επαυξάνουμε τα δείγματα βάζοντας το 1 στην πρώτη θέση τους. Παρακάτω φαίνονται τα updates που γίνονται στις πρώτες εποχές

i	$f(w(t)*x(i))$	Correction	$w(t)$	$w(t+1)$
0	1	$[-1. \ -2. \ -1.5]$	$[0 \ 0 \ 0]$	$[-1. \ -2. \ -1.5]$
2	1	$[-1. \ 3. \ -3.]$	$[-1. \ -2. \ -1.5]$	$[-1. \ 3. \ -3.]$
5	0	$[1. \ -1. \ 0.]$	$[-1. \ 3. \ -3.]$	$[1. \ -1. \ 0.]$
7	0	$[1. \ 2. \ -0.5]$	$[1. \ -1. \ 0.]$	$[1. \ 2. \ -0.5]$
9	0	$[1. \ -2. \ 1.]$	$[1. \ 2. \ -0.5]$	$[1. \ -2. \ 1.]$

i	$f(w(t)*x(i))$	Correction	$w(t)$	$w(t+1)$
2	1	$[-1. \ 3. \ -3.]$	$[1. \ -2. \ 1.]$	$[0. \ 1. \ -2.]$
5	0	$[-1. \ 3. \ -3.]$	$[0. \ 1. \ -2.]$	$[0. \ 1. \ -2.]$
9	0	$[-1. \ 3. \ -3.]$	$[0. \ 1. \ -2.]$	$[0. \ 1. \ -2.]$

i	$f(w(t)*x(i))$	Correction	$w(t)$	$w(t+1)$
1	1	$[-1. \ -4. \ -1.]$	$[0. \ 1. \ -2.]$	$[-1. \ -3. \ -3.]$
6	0	$[1. \ 0. \ 0.]$	$[-1. \ -3. \ -3.]$	$[1. \ 1. \ -2.]$
9	0	$[1. \ -2. \ 1.]$	$[1. \ 1. \ -2.]$	$[1. \ -1. \ -1.]$

Μετά από 14 εποχές ολοκληρώνεται η εκτέλεση και προκύπτουν τα βάρη $w = [4, -2, -7]$ οπότε η ευθεία είναι η $4 - 2x - 7y = 0$ όπως φαίνεται και στη γραφική παράσταση



Παρατίθεται ο κώδικας του perceptron

```
def f(vect, weight):
    res = np.round(np.dot(vect, weight), decimals=2)
    if res < 0:
        return 0
    else:
        return 1

def one_cycle(weight, x, y, b):
    stuff = []
    temp_w = weight
    for i in range(len(x)):
        estimate = f(x[i], temp_w)
        if y[i] == estimate:
            continue
        if np.round(np.dot(weight, x[i]), 2) <= 0 and y[i] == 1:
            weighted_x = b * x[i]
        elif np.round(np.dot(weight, x[i]), 2) >= 0 and y[i] == 0:
            weighted_x = - b * x[i]

        new_w = weight + weighted_x
        stuff.append([i, estimate, weighted_x, temp_w, new_w])
        temp_w = new_w
    return (stuff, temp_w)
```

```
def train(weight, x_train, y_train, b_param, max_epochs=5):
    stuff = []
    for i in range(max_epochs):
        (stuff, weight) = one_cycle(weight, x_train, y_train, b_param)
        if not stuff:
            break
        print(tabulate(stuff, headers=['i', 'f(w(t)*x(i))', 'Correction', 'w(t)', 'w(t+1)']))
        print('\n')
    return weight
```

Άσκηση 1.5

Επιλέγω να αντικαταστήσω τη δεδομένη κατανομή στην p_2 και να θεωρήσω ότι άγνωστη είναι η p_1 οπότε

$$D_{KL} = \int p_1(x) \ln p_1(x) dx - \int p_1(x) \ln p_2(x) dx$$

$$= \int p_1(x) \ln p_1(x) dx + \frac{1}{2} \int p_1(x) [d \ln(2\pi) + \ln |\Sigma| + (x - \mu)^T \Sigma^{-1} (x - \mu)] dx$$

Για την ελαχιστοποίηση αρκεί να πάρω τις παραγώγους ως προς μ και Σ^{-1} ως εξής

$$\frac{\partial D_{KL}}{\partial \mu} = - \int \Sigma^{-1} (x - \mu) p_1(x) dx = 0$$

Η παραπάνω σχέση απλοποιείται σε

$$\int p_1(x) (x - \mu) dx = E[x - \mu] = 0 \Rightarrow \mu = E[x]$$

Παραγωγίζοντας ως προς Σ^{-1}

$$\frac{\partial D_{KL}}{\partial \Sigma^{-1}} = \int p_1(x) [-\Sigma + (x - \mu)(x - \mu)^T] dx = 0$$

Η σχέση απλοποιείται σε

$$E[\Sigma - (x - \mu)(x - \mu)^T] = 0 \Rightarrow \Sigma = E[(x - \mu)(x - \mu)^T]$$

Άσκηση 1.6

Ερώτημα 1

Το σφάλμα του linear regression προκύπτει από τη διαφορά μεταξύ της σωστής τιμής και της πρόβλεψης δηλαδή

$$error_i = y_i - w^T x_i$$

Αν υποθέσουμε ότι αυτό το σφάλμα ακολουθεί κανονική κατανομή $N(0, \sigma^2)$ τότε η λύση μέγιστης πιθανοφάνειας προκύπτει ως εξής

$$\ln L = \sum \left\{ \ln(2\pi\sigma^2) + \frac{-(y_i - w^T x_i)^2}{2\sigma^2} \right\}$$

Η συγκεκριμένη ποσότητα μεγιστοποιείται όταν ελαχιστοποιείται το

$$\sum (y_i - w^T x_i)^2$$

Όμως αυτό είναι ακριβώς η λύση που ψάχνει ο αλγόριθμος LMS. Άρα οι λύσεις είναι ισοδύναμες.

Ερώτημα 2

Ψάχνουμε ευθεία της μορφή $y = b + ax$ οπότε χρησιμοποιώντας τη μέθοδο ελάχιστων τετραγώνων έχουμε τους εξής τύπους

$$a = \frac{n \left(\sum_{i=1}^n x_i y_i \right) - \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n y_i \right)}{n \left(\sum_{i=1}^n x_i^2 \right) - \left(\sum_{i=1}^n x_i \right)^2},$$
$$b = \frac{\left(\sum_{i=1}^n x_i^2 \right) \left(\sum_{i=1}^n y_i \right) - \left(\sum_{i=1}^n x_i y_i \right) \left(\sum_{i=1}^n x_i \right)}{n \left(\sum_{i=1}^n x_i^2 \right) - \left(\sum_{i=1}^n x_i \right)^2}$$

Κάνοντας τις πράξεις προκύπτει η ευθεία $y = 1.228 + 2.204x$

Ερώτημα 3

Ο αλγόριθμος LMS κάνει update τα βάρη με βάση τον παρακάτω κανόνα

$$w(t+1) = w(t) + r * (y_n - w(t)^T x_n) * x_n$$

Για την συγκεκριμένη εκτέλεση αρχικοποιώ το $w(0) = [1, 1]$ και επιλέγω $r = 0.1$ και η εκτέλεση φαίνεται στον πίνακα

x_n	y_n	w	$r(y_n - w(t)^T x_n)x_n$
0.38	2.05	[1, 1]	[0.067, 0.025]
0.44	2.23	[1.067, 1.025]	[0.071, 0.031]
0.48	2.13	[1.14, 1.056]	[0.048, 0.023]
0.54	2.33	[1.186, 1.08]	[0.056, 0.03]
0.58	2.67	[1.242, 1.11]	[0.078, 0.045]
0.64	2.68	[1.32, 1.155]	[0.062, 0.039]
0.71	2.81	[1.38, 1.195]	[0.057, 0.041]
0.76	2.97	[1.44, 1.236]	[0.058, 0.044]
0.82	3.12	[1.499, 1.281]	[0.057, 0.0467]
0.96	3.20	[1.556, 1.327]	[0.368, 0.353]

Τελικά προκύπτει η ευθεία $y = 1.59 + 1.363x$

Ερώτημα 4

Εκτελώντας την παραπάνω διαδικασία για 100 εποχές στην Pythοn παίρνω μια πολύ καλύτερη προσέγγιση $y = 1.32 + 2.07x$.

Παρακάτω δίνεται ο κώδικας

```
def initialise_weights(size):
    return np.ones(size)

def update_weights(w, x, y, r = 0.05):
    pred = np.dot(w, x)
    diff = y - pred
    update = r * diff * x
    return np.add(w, update)

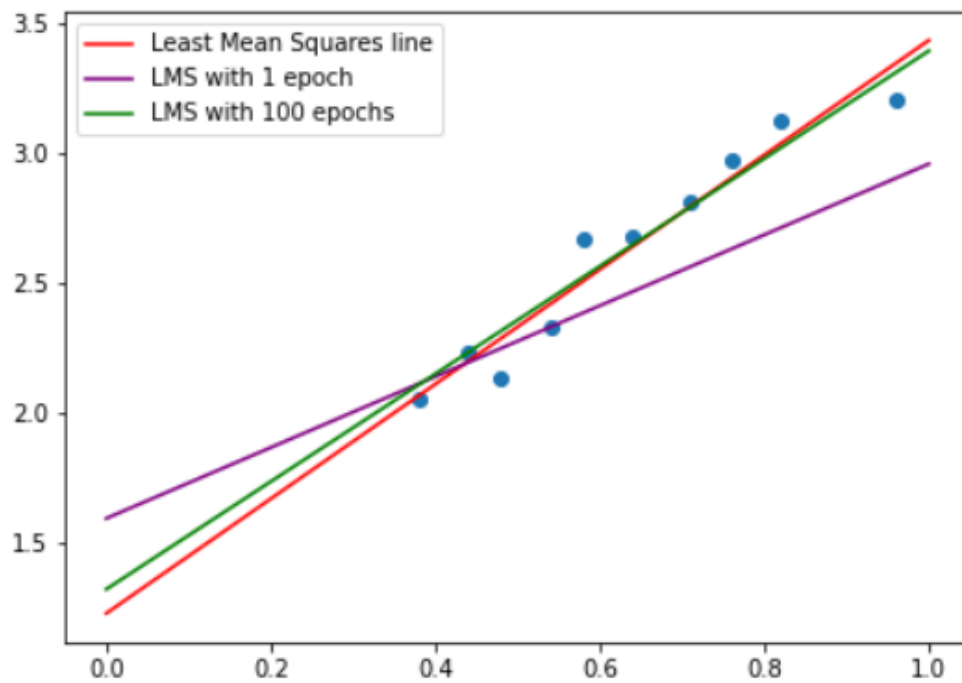
def mean_square_error(w, samples, values):
    error = 0
    for x, y in zip(samples, values):
        pred = np.dot(w, x)
        diff = y - pred
        error += diff ** 2
    return 0.5 * error
```



```
def lms(samples, values, r=0.05, max_epoch=5):
    w = initialise_weights(samples.shape[1])
    w_new = initialise_weights(samples.shape[1])
    epoch = 0
    while epoch < max_epoch:
        for x, y in zip(samples, values):
            error = mean_square_error(w, samples, values)
            w_new = update_weights(w, x, y, r)
            w = w_new.copy()
        epoch += 1
    return w
```

Ερώτημα 5

Όλα τα παραπάνω αποτελέσματα αποτυπώνονται στην γραφική παράσταση



Άσκηση 1.7

Ερώτημα 1

Η κλάση ενός δείγματος αποφασίζεται με βάση το πρόσημο της διαφοράς των δύο κατανομών

$$g(x) = p(\omega_1|x) - p(\omega_2|x) = p(x|\omega_1)p(\omega_1) - p(x|\omega_2)p(\omega_2)$$

Άρα για $x \in [0, 1]$ ισχύει

$$g(x) = 2x - 1$$

Άρα το σημείο απόφασης είναι το

$$g(x) = 0 \Rightarrow x = \frac{1}{2}$$

Η πιθανότητα σφάλματος είναι η εξής

$$P(error) = \int_{R_1} p(\omega_2|x)dx + \int_{R_2} p(\omega_1|x)dx = \int_{\frac{1}{2}}^1 1 - x dx + \int_0^{\frac{1}{2}} x dx = \frac{1}{4}$$

Ερώτημα 2

Έστω ότι επιλέξαμε τα $x_1 \in \omega_1, x_2 \in \omega_2$ και $x \in \omega_1$. Η πιθανότητα σφάλματος του νέου ταξινομητή είναι η πιθανότητα το x να βρίσκεται πιο κοντά στο x_2 από ότι στο x_1 . Άρα έχουμε την ανισότητα

$$|x - x_1| \leq |x - x_2| \Rightarrow$$

$$(x - x_1)^2 \leq (x - x_2)^2 \Rightarrow$$

$$(x_1 - x_2)(x_1 + x_2 - 2x) \geq 0 \Rightarrow$$

$$x_1 \geq x_2, x \leq \frac{x_1 + x_2}{2} \text{ ή } x_1 \leq x_2, x \geq \frac{x_1 + x_2}{2}$$

Άρα

$$\begin{aligned} P[error] &= P[d_1 \geq d_2 | x, x_1 \in \omega_1, x_2 \in \omega_2] = \\ &= \int_0^1 p(x_1|\omega_1) \int_0^{x_1} p(x_2|\omega_2) \int_0^{\frac{x_1+x_2}{2}} p(x|\omega_1) dx dx_2 dx_1 \\ &+ \int_0^1 p(x_1|\omega_1) \int_{x_1}^1 p(x_2|\omega_2) \int_{\frac{x_1+x_2}{2}}^1 p(x|\omega_1) dx dx_2 dx_1 \end{aligned}$$

Άσκηση 1.8

Το $Q(\theta, \theta^0)$ υπολογίζεται ως εξής

$$\begin{aligned} Q(\theta, \theta^0) &= \int [\sum \ln p(x_k | \theta)] * p(x_{32} | \theta^0, x_{31} = 1) dx_{32} \\ &= \ln p(x_1 | \theta) + \ln p(x_2 | \theta) + \int \ln p(x_3 | \theta) * \frac{p(x_3 | \theta^0)}{\int p(x'_3 | \theta^0) dx'_{32}} dx_{32} \\ &= \ln p(x_1 | \theta) + \ln p(x_2 | \theta) + 2e^2 \int \ln p(x_3 | \theta) * p(x_3 | \theta^0) dx_{32} \end{aligned}$$

Θα πρέπει να ισχύει $\theta_2 \geq 5$ αλλιώς $Q(\theta, \theta^0) = -\infty$, οπότε

$$\begin{aligned} Q(\theta, \theta^0) &= \ln p(x_1 | \theta) + \ln p(x_2 | \theta) + 2e^2 \int_0^3 \ln p(x_3 | \theta) * p(x_3 | \theta^0) dx_{32} \\ &= -6\theta_1 - 3\ln\theta_1\theta_2 \end{aligned}$$

Λόγω κανονικοποίησης της πρώτης κατανομής θα πρέπει

$$\int \frac{1}{\theta_1} e^{-\theta_1 x_1} dx_1 = 1 \Rightarrow \theta_1 = 1$$

Αντικαθιστώντας

$$Q(\theta, \theta^0) = -6 - 3\ln\theta_2$$

Η οποία συνάρτηση μεγιστοποιείται για $\theta_2 = 5$ λόγω του περιορισμού και επειδή είναι φθίνουσα.

Άρα οι κατανομές πριν και μετά είναι οι εξής

